Estudo Comparativo de Metodologias e Recursos em SSVEP-BCI: Da Modelagem Espectral à Aprendizagem em Variedades

Victor Angelo Souza Santos[1]

[1]

Resumo. *As Interfaces Cérebro-Computador baseadas em Potenciais Evocados Visuais de Regime Estacionário (SSVEP-BCI) oferecem altas taxas de transferência de informação, mas enfrentam desafios críticos como calibrações individuais exaustivas e baixa generalização inter-sujeito (cross-subject). Este relatório apresenta um levantamento sistemático de quatro artigos seminais do estado da arte: a base de dados de referência BETA, a rede compacta Task-Attention ANN, o modelo de duplo ramo espectral DB-AFDNet e a rede geométrica MAtt em variedades Riemannianas. Analisam-se detalhadamente: (1) as metodologias de processamento e arquiteturas neurais propostas, (2) os resultados quantitativos de acurácia, ITR e recursos abertos disponíveis, e (3) perspectivas e hipóteses de trabalho para a disciplina, culminando em uma proposta de decodificação compacta e não-euclidiana com redução de eletrodos.*

Palavras-chave*: SSVEP. Interface Cérebro-Computador. Deep Learning. Mecanismos de Atenção. Geometria Riemanniana.*

1. Introdução

Interfaces Cérebro-Computador (BCIs) estabelecem canais diretos de comunicação entre padrões neurais e comandos em dispositivos computacionais. Dentre as modalidades não invasivas baseadas em eletroencefalograma (EEG), os sistemas fundamentados em Potenciais Evocados Visuais de Regime Estacionário (*Steady-State Visual Evoked Potentials* - SSVEP) destacam-se pela robusta relação sinal-ruído (SNR) e elevada Taxa de Transferência de Informação (ITR). Tais potenciais manifestam-se no córtex visual primário em frequências sincronizadas às cintilações dos estímulos observados pelo usuário.

Não obstante seus benefícios, as aplicações práticas defrontam-se com limitações severas. Métodos clássicos dependem de calibrações extensas por sujeito para ajuste de filtros espaciais, provocando fadiga mental e reduzindo a usabilidade. Paralelamente, redes neurais profundas convencionais requerem volumes proibitivos de dados de treino e exibem desempenho instável em cenários inter-sujeito (*cross-subject*), decorrente da não-estacionariedade dos sinais cerebrais e do ruído do escalpo.

Para superar esses entraves, a literatura recente converge para arquiteturas informadas pela física e fisiologia do sinal, empregando mecanismos de atenção temporal, espacial e espectral, bem como representações em variedades não-euclidianas. Este trabalho compila um estudo analítico de quatro referências chaves: o banco de dados em larga escala BETA (Liu et al., 2020), a rede compacta baseada em atenção da tarefa (Wang et al., 2023), a rede de duplo ramo no domínio da frequência DB-AFDNet (Yang et al., 2025/2026) e o arcabouço de aprendizado geométrico MAtt (Pan et al., 2022).

2. Metodologia Utilizada nos Artigos Selecionados

Os artigos convergem no emprego de sinais SSVEP gerados predominantemente por modulação conjunta de frequência e fase (*Joint Frequency and Phase Modulation* - JFPM), porém adotam formulações metodológicas distintas para decodificação.

2.1. BETA: Caracterização e Métricas Populacionais

O estudo de Liu et al. (2020) estabeleceu um benchmark com 70 voluntários sob paradigma de soletração visual de 40 alvos (frequências de 8,0 a 15,8 Hz, passos de 0,2 Hz; fases de 0 a 1,5π) estruturado como teclado QWERTY. O diferencial metodológico residiu na gravação fora de câmara de blindagem eletromagnética e na redução para apenas 4 blocos de calibração por sujeito. O pré-processamento emprega filtro passa-faixa digital de fase zero (3–100 Hz), entalhe (*notch*) em 50 Hz, subamostragem a 250 Hz e compensação da latência visual em 130 ms.

Como contribuição teórica, o trabalho formulou o conceito de *Wide-band SNR* (SNR em banda larga), computando a razão entre a soma das potências dos cinco primeiros harmônicos e a densidade espectral total subtraída dos harmônicos. Adicionalmente, introduziu-se o *BCI Quotient*, normalizando a SNR individual em uma distribuição $\mathcal{N}(100, 15)$ para caracterizar o nível de aptidão e resposta fisiológica do usuário à tecnologia BCI.

2.2. Compact ANN: Integração de Conhecimento Prévio da Tarefa

Visando erradicar o *overfitting* de redes profundas com poucos dados de calibração individual, Wang et al. (2023) desenharam uma rede compacta baseada em *Task Attention*. O sinal é filtrado em 7–90 Hz e particionado em um banco de filtros harmônicos (*Filter Bank*) com $G = 5$ sub-bandas.

A inovação metodológica consiste em substituir as matrizes de projeção tradicionais de autoatenção (*self-attention*) por núcleos fixos pré-definidos: referências senoidais teóricas (R_i) e gabaritos empíricos médios individuais calculados via *leave-one-block-out* ($\overline{X}_i$), eliminando o aprendizado cego de parâmetros e o vazamento de dados. Nas camadas espaciais e de características, a imposição de restrições rígidas de pesos compartilhados entre os estímulos ($W_{1,w} = \cdots = W_{I,w}$ e $V_{1,v} = \cdots = V_{I,v}$) comprime o espaço de otimização para ínfimos 335 parâmetros treináveis ponta a ponta via gradiente descendente com perda por entropia cruzada categórica.

2.3. DB-AFDNet: Duplo Ramo Espectral e Desacoplamento de Padrões

Yang et al. (2025/2026) abordaram a decodificação estritamente inter-sujeito (*cross-subject*) através de uma rede de duplo ramo orientada por atenção. Os sinais (filtrados entre 8 e 64 Hz) passam por FFT com preenchimento por zeros (*zero-padding*), segregando de forma explícita a parte real e a parte imaginária do espectro complexo em fluxos independentes.

Cada ramo é processado pelo módulo DIAN (*Domain Information Awareness Network*), composto por atenção espacial por canal baseada em *Squeeze-and-Excitation* (SE) e blocos de atenção adaptativa multiescala com convoluções paralelas de diversos tamanhos de kernel $(1, 3, \ldots, 2G - 1)$. Para guiar a generalização, os autores integraram duas funções de restrição na perda total ($\mathcal{L} = \mathcal{L}_c + \lambda_1 \mathcal{L}_d + \lambda_2 \mathcal{L}_s$):

1. **Similaridade Inter-ramos** ($\mathcal{L}_d$): penalização por norma L_1 entre os pesos de atenção dos ramos, forçando a extração de representações consensuais;
2. **Ortogonalidade Intra-ramo** ($\mathcal{L}_s$): penalização por norma de Frobenius quadrática entre as características consensuais e específicas de cada componente, expurgando redundâncias espectrais.

2.4. MAtt: Aprendizado Profundo em Variedades Riemannianas

Pan et al. (2022) formularam o modelo MAtt para mitigar a baixa relação sinal-ruído e a não-estacionariedade através do Aprendizado Profundo Geométrico (*Geometric Deep Learning* - GDL). Após convoluções preliminares no espaço euclidiano, os *embeddings* latentes são segmentados em m subjanelas temporais e mapeados na variedade riemanniana de matrizes Simétricas Definidas Positivas (SPD, $\mathrm{Sym}^+(n)$) através de matrizes de covariância amostrais (SCM) com regularização traço-unitária (ϵI, com $\epsilon = 10^{-5}$).

Na variedade, o mecanismo de atenção calcula a matriz de similaridade geodésica baseada na métrica Log-Euclidiana (δ_L):

$$\mathrm{sim}(q_i, k_j) = \frac{1}{1 + \log(1 + \delta_L(q_i, k_j))} = \alpha_{ij} \tag{1}$$

As matrizes resultantes são combinadas por média Log-Euclidiana ponderada. A retropropagação dos gradientes ocorre sobre a variedade de Stiefel $St(p, n)$, preservando a ortogonalidade dos pesos por projeção tangente e retração via decomposição QR. A conversão de retorno para classificação euclidiana efetua-se mediante achatamento logarítmico ($\mathrm{flatten}(\mathrm{Log}(\cdot))$) associado a camadas ReEig (limiar sobre autovalores).

3. Resultados e Materiais Disponíveis

A Tabela 1 sintetiza os conjuntos de dados, as parametrizações experimentais, as métricas-chave obtidas e os links de acesso público documentados nas obras.

Tabela 1. Quadro comparativo de métodos, bases de dados, protocolos e métricas de desempenho.

Artigo	Arquitetura / Abordagem	Dataset(s) e Sujeitos	Validação	Desempenho Chave	Código / Dados
BETA (Liu et al., 2020)	Benchmark (11 métodos clássicos supervisionados e *training-free*)	BETA (70 suj., 64 canais, 9 parieto-occipitais ativos)	Leave-One-Block-Out individual	msTRCA: ITR de $145,26 \pm 8,15$ bpm (0,6 s); FBCCA: $98,79 \pm 4,49$ bpm (1,4 s)	`Tsinghua: BETA` `Figshare: BETA`
Compact ANN (Wang et al., 2023)	Task-Attention ANN enxuta (335 parâmetros treináveis)	Benchmark (35 suj.) e BETA (70 suj.), 9 canais	Leave-One-Block-Out individual	ITR de 182,05 bpm (0,5 s) no Benchmark; ITR de 137,31 bpm (0,6 s) no BETA	`GitHub: Compact-ANN`
DB-AFDNet (Yang et al., 2026)	Dual-Branch Complexo com atenções espacial e multiescala ($\mathcal{L}_d$, $\mathcal{L}_s$)	Benchmark (35 suj.), BETA (70 suj.) e Próprio (12 suj.), 9 canais	Leave-One-Subject-Out (LOSO)	Acurácia em 1,0 s de 84,02% (Bench.) e 74,33% (BETA); ITR máx. de 154,76 bpm; inferência em 0,0062 s	`GitHub: DB-AFDNet`
MAtt (Pan et al., 2022)	Manifold Attention em variedades SPD e Stiefel (GDL)	MAMEM-SSVEP-II (11 suj., 8 canais), BCIC-IV-2a (MI), BCI-ERN	Cross-Session individual	Acurácia de $65,50 \pm 8,20\%$ em SSVEP (1,0 s) e $74,71 \pm 5,01\%$ em MI; supera baselines euclidianos	`GitHub: MAtt`

A análise comparativa revela que o banco de dados BETA provê condições substancialmente mais desafiadoras e representativas da vida real: a SNR em banda larga de suas amostras situou-se significativamente abaixo da base Benchmark tradicional ($-13,78$ dB versus $-10,92$ dB, $p < 0,001$). Em termos de modelagem, o DB-AFDNet e a Compact ANN ratificaram a utilidade da seleção restrita de 9 eletrodos na área visual (Pz, PO3, PO5, PO4, PO6, POz, O1, Oz e O2). O DB-AFDNet demonstrou viabilidade para operação online estrita, com tempo de inferência por amostra de apenas 0,0062 s, enquanto a Compact ANN reduziu em mais de 99,8% o volume de parâmetros frente a DNNs concorrentes convencionais. Por sua vez, o MAtt comprovou experimentalmente a superioridade do espaço Riemanniano sobre o espaço Euclidiano: módulos de atenção na variedade SPD atingiram 65,50% de acurácia em SSVEP frente a apenas 22,91% obtidos pela atenção convencional (FE+SA) sob idênticas condições de ablação.

4. Perspectivas, Hipóteses e Ideias para a Disciplina

Os resultados levantados apontam uma rota consistente de evolução: afastar-se de modelos profundos de arquitetura cega e avançar na intersecção entre conhecimento neurofisiológico prévio, decomposição espectral estruturada e aprendizado geométrico.

4.1. Hipótese de Pesquisa Central

Formula-se a seguinte hipótese para guiar os experimentos práticos ao longo da disciplina:

> *"A integração da decomposição espectral complexa desacoplada (do DB-AFDNet) com restrições de projeção geométrica em variedades SPD (do MAtt) viabiliza a criação de um decodificador compacto e robusto que preserva taxas de acurácia e ITR competitivas no dataset BETA sob avaliação cross-subject sem necessidade de calibração prévia, operando com montagens reduzidas a apenas 3 a 5 canais occipitais."*

4.2. Plano de Ação e Ideias Práticas

A fim de testar a hipótese, delineiam-se os seguintes eixos de implementação computacional:

1. **Hibridização Espectral-Riemanniana:** Enquanto o DB-AFDNet trata características de frequência através de camadas lineares e atencionais, propõe-se computar matrizes de covariância cruzada entre as componentes harmônicas reais e imaginárias. Essas matrizes serão inseridas na variedade SPD com a métrica Log-Euclidiana do MAtt, capturando desvios de fase inter-sujeito sem distorções no espaço Euclidiano.
2. **Avaliação Sistemática de Montagens Mínimas:** O conjunto BETA oferece 64 canais, porém a literatura foca em 9 eletrodos parieto-occipitais. Como projeto prático, investigará-se a degradação de acurácia frente à redução progressiva para 5 eletrodos (POz, PO3, PO4, Oz, O1) e 3 eletrodos (O1, Oz, O2), verificando se a atenção adaptativa compensa a perda de cobertura espacial.
3. **Decodificação em Janelas Ultracurtas ($<$ 0,5 s):** Em aplicações de alta velocidade, janelas temporais de 0,2 a 0,4 s são críticas. Avaliar-se-á se o desacoplamento espectral com restrições ortogonais mitiga a deterioração do ITR em janelas curtas no dataset BETA.

4. **Fluxo de Reprodutibilidade com PyTorch:** Utilizando os repositórios públicos oficiais disponibilizados pelos autores, será estabelecido um ambiente experimental único em Python/PyTorch para carregar as matrizes `.mat` do BETA, estabelecendo como baselines os algoritmos FBCCA/msTRCA e confrontando-os com as implementações neurais.

5. Conclusão

Este trabalho consolidou uma análise detalhada sobre quatro referências centrais em decodificação de SSVEP. Constatou-se que o avanço da área depende da superação da dependência de calibrações individuais e do ruído experimental. A incorporação de gabaritos teóricos (como na Compact ANN), a separação explícita de componentes espectrais complexas com atenção (DB-AFDNet) e a projeção em variedades Riemannianas (MAtt) representam soluções de alta eficácia comprovada no desafiador dataset BETA. Como perspectiva direta, a unificação desses conceitos provê uma proposta de pesquisa factível, com código e dados públicos, abrindo caminho para o desenvolvimento prático do classificador híbrido compacto durante a disciplina.

Referências

[1] Liu, B., Huang, X., Wang, Y., Chen, X., e Gao, X. (2020). BETA: A Large Benchmark Database Toward SSVEP-BCI Application. *Frontiers in Neuroscience*, 14, 627.

[2] Wang, Z., Wong, C. M., Wang, B., Feng, Z., Cong, F., e Wan, F. (2023). Compact Artificial Neural Network Based on Task Attention for Individual SSVEP Recognition With Less Calibration. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 31, 2525-2534.

[3] Yang, Y., Wang, Z., Jia, Z., Wang, B., Zhang, S., Wong, C. M., Gao, X., Jung, T.-P., e Wan, F. (2026). Dual-Branch Attention-Based Frequency Domain Network for Cross-Subject SSVEP-BCIs. *IEEE Journal of Biomedical and Health Informatics*, 30(5), 4096-4107.

[4] Pan, Y.-T., Chou, J.-L., e Wei, C.-S. (2022). MAtt: A Manifold Attention Network for EEG Decoding. In: *Advances in Neural Information Processing Systems (NeurIPS 2022)*, 35, 1-14.